

Análise Comparativa de Arquiteturas *Deep Learning* para Reconhecimento de Expressões Faciais

Experiência Criativa: Projeto Transformador II
Bacharelado em Ciência da Computação – PUCPR

Turma U – Equipe 2

Alexandre C. A. Beiruth, João G. Cunha, Leandro C. Vieira, Luana T. H. Cordeiro
{ alexandre.beiruth, joao.cunha, cardoso.vieira, luana.halicki }@pucpr.edu.br

I. INTRODUÇÃO

O *Facial Expression Recognition* (FER) consolidou-se como uma área de pesquisa fundamental na interseção entre visão computacional e interação humano-computador [1]. Modelos de *Deep Learning* (DL), como *Convolutional Neural Networks* (CNNs) e *Vision Transformers* (ViTs), têm alcançado resultados de ponta em *datasets* de referência, como o *Real-world Affective Faces Database* (RAF-DB) [2]. No entanto, a aplicação prática desses modelos em cenários do mundo real (*in-the-wild*) revela um desafio crítico: uma degradação significativa de desempenho quando o modelo é testado em dados com características diferentes das vistas no treinamento (ex: iluminação variada, oclusões parciais, poses de cabeça extremas), fenômeno conhecido como *Cross-Dataset Drift* (CDD) [3] [4].

Modelos de FER inadvertidamente aprendem as “assinaturas” de um *dataset* específico e falham em generalizar para outro, mesmo que ambos se proponham a cobrir o mesmo domínio *in-the-wild* [5]. Isso representa um obstáculo direto para a implementação de sistemas de FER robustos e confiáveis.

Ainda que o CDD seja um conceito estabelecido, a revisão da literatura revelou uma escassez de estudos dedicados à comparação sistemática das diferentes famílias de arquiteturas — CNNs clássicas (*Residual Network 50 layers* (ResNet-50)), CNNs modernas e eficientes (*EfficientNet Architecture* (EfficientNet)) e arquiteturas híbridas (*Efficient Vision Transformer* (EfficientViT)) — que respondem a esse desafio.

Este artigo busca preencher essa lacuna, investigando rigorosamente a robustez ao CDD. Avaliamos essas três arquiteturas em dois *datasets in-the-wild* (RAF-DB e *Expression in-the-Wild Database* (ExpW)) e propomos um *pipeline* de dados em duas fases (balanceamento *offline* e *augmentation online*) para mitigar a perda de generalização.

Este trabalho apresenta três contribuições principais. Primeiramente, realizamos uma comparação sistemática da robustez das arquiteturas ResNet-50, EfficientNet e EfficientViT frente ao CDD, investigando seu desempenho em cenários de treino e teste cruzados entre os conjuntos RAF-DB e ExpW. Posteriormente, avaliamos um *pipeline* de pré-processamento em duas fases, que combina *oversampling offline* com *aug-*

mentation leve, além de *augmentation online* mais intenso por meio do *Albumentations*, com o objetivo de melhorar a capacidade de generalização dos modelos. Por fim, analisamos o *trade-off* entre acurácia e eficiência computacional (tempo e memória) para cada arquitetura considerada.

O restante deste artigo está organizado da seguinte forma. A Seção II revisa a literatura sobre FER *in-the-wild*, descreve as arquiteturas estudadas e aborda o CDD. Na Seção III, apresentamos nossa metodologia e o protocolo experimental adotado. Em seguida, na Seção IV, discutimos os resultados quantitativos e qualitativos obtidos. Por fim, a Seção V oferece as conclusões do estudo e aponta possíveis direções para trabalhos futuros.

II. TRABALHOS RELACIONADOS

A literatura em FER tem evoluído rapidamente com a adoção de DL. Esta seção revisa os avanços em três áreas centrais para este trabalho: o desafio de atuar em ambientes *in-the-wild*, as arquiteturas de DL relevantes e o problema da generalização entre *datasets*.

A. FER em Ambientes In-the-Wild

Os primeiros trabalhos em FER focavam em *datasets* capturados em laboratório (ex: CK+ [6], JAFFE [7]). Embora úteis, esses dados não refletem a complexidade do mundo real. Para resolver isso, a comunidade desenvolveu *datasets in-the-wild*, como RAF-DB [2] e ExpW [8]. Esses *datasets* contêm imagens com oclusões, iluminação variada e poses de cabeça não-controladas, tornando-se *benchmarks* essenciais para testar a robustez de novos métodos [3]. *Surveys* recentes, como o de Canal et al [1] e Dalvi et al [9], apontam que, apesar dos avanços, a performance dos modelos nestas condições ainda é um desafio aberto, principalmente devido à dificuldade de generalização.

B. Arquiteturas de Deep Learning para Visão

A evolução das CNNs foi um marco para o FER. A ResNet-50 [10] introduziu conexões residuais, permitindo o treino de redes muito mais profundas sem sofrer com o desaparecimento do gradiente, estabelecendo-se como um forte *baseline* [11]. Posteriormente, a EfficientNet [12] propôs um método de

escalonamento composto (profundidade, largura e resolução), criando modelos com alta acurácia e eficiência computacional.

Mais recentemente, arquiteturas híbridas que unem CNNs e ViTs [13] têm ganhado destaque. O EfficientViT [14], foco principal deste trabalho, utiliza uma nova atenção linear multi-escala para alcançar um balanço robusto entre desempenho e eficiência, superando arquiteturas CNN e ViT tradicionais em tarefas de visão densa.

C. Cross-Dataset Drift (CDD)

Um modelo treinado em um *dataset* frequentemente falha ao ser testado em outro, mesmo que ambos retratem o mesmo problema. Este fenômeno é conhecido como CDD [4]. No contexto do FER, [5] discute como as expressões *in-the-wild* possuem variações culturais e contextuais que são capturadas como vieses pelos modelos. Trabalhos como o de Shahzad et al [15], mostram que treinar em uma mistura de *datasets* pode melhorar a generalização. No entanto, uma análise comparativa de como ResNet-50, EfficientNet e EfficientViT resistem especificamente ao CDD em FER *in-the-wild* permanece uma lacuna. Nosso trabalho se insere neste contexto, utilizando os experimentos *cross-dataset* para medir essa robustez.

III. METODOLOGIA

Esta seção constitui o núcleo técnico do trabalho e detalha a abordagem adotada para avaliar a robustez das arquiteturas de DL. A metodologia é dividida em quatro etapas principais: seleção e preparação dos conjuntos de dados, definição das arquiteturas de modelo, protocolo experimental para treinamento e avaliação, e por fim, as métricas de desempenho e custo computacional.

A. Conjuntos de Dados In-the-Wild

Para endereçar o desafio do CDD, selecionamos dois *datasets* de FER *in-the-wild* publicamente disponíveis: RAF-DB [2] e ExpW [8]. Ambos contêm imagens com oclusões, poses variadas e condições de iluminação não controladas, características essenciais para esta análise de robustez.

A Figura 1 ilustra a alta variabilidade e os desafios (como oclusões e ângulos extremos) presentes em ambos os *datasets*. O desbalanceamento de classes, um problema notório em FER *in-the-wild*, é detalhado na Tabela I.

B. Pipeline de Pré-processamento e Augmentation

Para garantir que os modelos aprendam características relevantes das expressões e não vieses dos dados, implementamos um *pipeline* robusto em três fases, ilustrado na Figura 2. Esta abordagem é fundamentada nas melhores práticas da área, que reconhecem a *data augmentation* como “não-negociável” para a robustez.

1) *Fase 1: Pré-processamento Padrão (Offline)*: Todas as imagens brutas do RAF-DB e ExpW passaram por um *pipeline* de padronização rigoroso.

1) *Detecção e Extração de Pontos-Chave*: O primeiro passo é localizar a face e seus componentes. Para isso, utilizamos a MTCNN [16]. A escolha desta ferramenta, amplamente adotada pela comunidade, deve-se à sua natureza



Figura 1. Exemplos de imagens dos *datasets* RAF-DB (linha superior) e ExpW (linha inferior). As colunas demonstram as emoções de nojo, felicidade e raiva, respectivamente. A figura ilustra os desafios *in-the-wild*, como oclusões, iluminação extrema e poses variadas.

Tabela I
ESTATÍSTICAS DO CONJUNTO DE TREINO PARA RAF-DB E ExpW, MOSTRANDO A DISTRIBUIÇÃO DE CLASSES ORIGINAL (*BASELINE*) E O RESULTADO DO NOSSO BALANCEAMENTO (*PROPOSTA*).

Classe	RAF-DB (Treino)		ExpW (Treino)	
	Original	Balanceado	Original	Balanceado
Felicidade	4772	4772	17605	23787
Tristeza	1982	4772	7918	25337
Surpresa	1290	4772	5332	24785
Raiva	705	4772	2829	24723
Nojo	717	4772	2976	23787
Medo	281	4772	840	25494
Neutro	2524	4772	23787	23787
Total	12271	33404	61287	171700



Figura 2. Pipeline de processamento de dados em três fases. A Fase 1 (Pré-processamento) padroniza os dados brutos (RGB para escala de cinza, redimensionamento 224x224) utilizando detecção facial MTCNN. A Fase 2 (Balanceamento Offline) mitiga o desbalanceamento de classes via *oversampling* com 30% de *augmentation* leve. A Fase 3 (Augmentation Online) aplica transformações probabilísticas (80%) em tempo real para forçar a generalização do modelo.

multi-task: além de detectar o *bounding box* da face, ela

fornece simultaneamente os pontos-chave (*landmarks*) dos olhos, que são essenciais para a próxima etapa.

- 2) Normalização Geométrica (Alinhamento): Com base nos *landmarks* dos olhos, a imagem é rotacionada para que a linha que os conecta fique perfeitamente horizontal. Este processo é crítico, pois remove a variação de rotação da cabeça no plano (*in-plane rotation*), simplificando a tarefa da rede neural. Ao garantir que todas as faces estejam verticais, o modelo não precisa mais aprender a reconhecer a mesma expressão em múltiplos ângulos, focando apenas nas características da emoção.
- 3) Padronização de Cor e Formato: Após o alinhamento e recorte da face, duas padronizações finais são aplicadas:
 - Conversão para Escala de Cinza: Esta é uma decisão metodológica para forçar o modelo a aprender com base na textura e forma das características faciais (ex: o formato da boca, as rugas ao redor dos olhos), em vez de informações de cor (como tom de pele ou cor da iluminação), que poderiam atuar como ruído ou vies.
 - Redimensionamento para 224x224 pixels: Este é o tamanho de entrada padrão exigido pelas arquiteturas ResNet-50, EfficientNet e EfficientViT. Como elas foram pré-treinadas no *dataset ImageNet Large Scale Visual Recognition Challenge* (ImageNet) com esta resolução, usar o mesmo tamanho é um requisito para alavancar o *transfer learning* e garantir um tensor de tamanho uniforme para o processamento em *batch*.

Para imagens onde a detecção facial falhou, um *fallback* de recorte central foi aplicado para evitar a perda de dados. O resultado desta fase são os *datasets* ‘processed_raf’ e ‘processed_expw’, que são limpos e padronizados, mas ainda desbalanceados.

2) *Fase 2: Balanceamento de Classes (Offline)*: O desbalanceamento de classes é um problema notório em *datasets* de FER (ver Tabela I). Para mitigar isso, aplicamos uma estratégia de balanceamento *offline*:

- 1) Estratégia: Aplicamos *Oversampling* no conjunto de treino. Todas as imagens originais são preservadas, e imagens das classes minoritárias são duplicadas até que todas as classes tenham o mesmo número de amostras da classe majoritária.
- 2) *Augmentation* Leve: Para evitar duplicatas exatas, uma probabilidade de 30% ($p=0.3$) de aplicar uma transformação da biblioteca *Albumentations* [17] é usada em cada imagem copiada. O *pipeline* aplica aleatoriamente uma das seguintes transformações: espelhamento horizontal, rotação, brilho/contraste, ruído gaussiano, desfoque, compressão JPEG, *pixel dropout* ou *shift/scale/rotate*.

O resultado desta fase são os *datasets* ‘augmented_raf’ e ‘augmented_expw’, que são balanceados e prontos para o experimento principal.

3) *Fase 3: Data Augmentation (Online)*: Para garantir variedade infinita de dados e forçar a generalização do modelo, aplicamos um *data augmentation* “pesado” em tempo real (*online*) durante o treinamento. A cada época, 80% ($p=0.8$) das imagens carregadas no *batch* recebem uma única transformação aleatória de um conjunto de seis opções da *Albumentations* [17]. Este *pipeline*, implementado com *A.OneOf*, seleciona aleatoriamente uma transformação de três categorias: geométrica (ex: *HorizontalFlip*, *ShiftScaleRotate*), intensidade (ex: *RandomBrightnessContrast*) ou ruído/desfoque (ex: *GaussianNoise*, *GaussianBlur*).

C. Arquiteturas de Deep Learning

Para a análise comparativa, selecionamos três arquiteturas que representam diferentes gerações e filosofias de modelos de visão computacional. A escolha das variantes *B0* do EfficientNet e EfficientViT foi intencional, alinhando-se ao nosso objetivo de analisar o *trade-off* entre acurácia e eficiência, uma vez que o sufixo *B0* designa a versão-base (*baseline*) dessas famílias, otimizada para o melhor custo-benefício computacional.

As arquiteturas avaliadas foram:

- ResNet-50: Uma CNN clássica que serve como um *benchmark* robusto. Sua principal inovação são as conexões residuais (*skip connections*), que permitem o treinamento de redes muito profundas ao mitigar o problema do desaparecimento do gradiente [10].
- EfficientNet (B0): Representante de CNNs modernas. Sua inovação é o escalonamento composto, uma fórmula que otimiza o balanço entre as três dimensões da rede (profundidade, largura e resolução de entrada) para alcançar alta acurácia com eficiência [12].
- EfficientViT (B0): Uma arquitetura híbrida e inovadora. Ela combina a eficiência das CNNs para extrair características locais (em baixa resolução) com a capacidade dos ViTs (*Transformers*) para capturar o contexto global da imagem, buscando um desempenho superior com custo computacional reduzido [14].

Todos os modelos, implementados em *PyTorch*, foram inicializados com pesos pré-treinados na ImageNet. Como esses pesos esperam uma entrada de 3 canais (RGB) e nossos dados estão em escala de cinza (1 canal), a etapa de carregamento de dados foi adaptada: cada imagem teve seu canal único triplicado (simulando uma imagem RGB), permitindo o uso dos pesos pré-treinados sem modificar a arquitetura interna dos modelos.

D. Protocolo Experimental e Métricas

Para avaliar o impacto do balanceamento e a robustez ao CDD, definimos quatro experimentos centrais (cenários de teste):

- 1) Experimento 1: *Baseline* Treinamento das três arquiteturas nos *datasets* desbalanceados (‘processed_raf’ e ‘processed_expw’).
- 2) Experimento 2: Proposta Treinamento das três arquiteturas nos *datasets* balanceados (‘augmented_raf’ e

‘augmented_expw’) e com a Fase 3 de *augmentation* online ($p=0.8$).

- 3) Experimento 3: Teste de *Cross-Dataset* Para medir o CDD diretamente, os modelos treinados no Experimento 2 (Proposta) são avaliados no conjunto de teste do outro *dataset*.
- 4) Experimento 4: Treino Combinado Um “super *dataset*” é criado unindo os conjuntos de treino ‘together_raf’ e ‘together_expw’. Os modelos são treinados nesta base combinada e avaliados nos dois conjuntos de teste separadamente.

Como hiperparâmetros de otimização, todos os treinos utilizaram uma configuração padrão-ouro para tarefas de classificação em DL:

- Otimizador Adam: Foi escolhido em detrimento de alternativas como o SGD. Adam é o otimizador *de facto* para a maioria das tarefas de visão, pois combina as vantagens do *Momentum* (para acelerar a convergência) com o *RMSProp* (para adaptar a taxa de aprendizado por parâmetro), oferecendo uma convergência robusta e rápida.
- Perda *Categorical Crossentropy*: Esta é a função de perda matematicamente correta para um problema de classificação *multi-classe* (7 emoções) e *single-label* (cada face tem apenas uma emoção). A rede é penalizada com base na sua confiança na classe correta.
- Mecanismos de *Callback*: Para garantir a reprodutibilidade e combater o sobreajuste (*overfitting*), dois *callbacks* foram essenciais. Primeiramente, o *EarlyStopping* monitorou a perda de validação (‘val_loss’) e interrompeu o treino se não houvesse melhora após 15 épocas (*patience=15*). Esta paciência oferece um balanço entre eficiência (não treinar desnecessariamente) e robustez (permitindo que o modelo escape de mínimos locais).
- Métrica de *Checkpoint*: Em segundo lugar, o *ModelCheckpoint* foi configurado para salvar *apenas* o modelo que apresentasse a menor perda de validação (‘val_loss’), e não o último modelo ou o de maior acurácia. A ‘val_loss’ é o indicador mais estável de generalização do modelo — sua capacidade de performar em dados nunca vistos —, garantindo que o modelo salvo seja o mais robusto, e não um que tenha apenas “decorado” os dados de treino.

Para uma avaliação completa, o protocolo experimental mediu duas categorias de métricas: desempenho de classificação e custo computacional.

1) *Métricas de Desempenho*: Para avaliar a performance de classificação, utilizamos Acurácia Geral, Precisão, *Recall* e *F1-Score*. Como os *datasets* “in-the-wild” são inerentemente desbalanceados, focamos nas métricas calculadas por classe e em sua média macro (*macro-average*).

A Acurácia Geral é apresentada como referência, mas a métrica chave de avaliação é o *F1-Score* Macro. Esta métrica, sendo a média do *F1-Score* de cada classe individual, garante que o modelo seja avaliado por sua capacidade de reconhecer

tanto as classes majoritárias (como “Felicidade”) quanto as minoritárias (como “Medo” ou “Nojo”). Adicionalmente, Matrizes de Confusão são utilizadas para uma análise qualitativa detalhada dos padrões de erro, identificando quais classes são mais frequentemente confundidas entre si.

2) *Métricas de Custo Computacional*: Para analisar o *trade-off* de eficiência, conforme exigido por nossa proposta, três métricas de custo foram registradas, alinhadas às nossas escolhas de arquiteturas *B0*:

- Tempo de Treinamento: O tempo total (em horas) para o modelo atingir a convergência (via *EarlyStopping*).
- Uso de Memória: O pico de uso de memória VRAM (GPU) e RAM (CPU) durante o treino e a inferência.
- Tempo de Inferência: O tempo médio (em milissegundos) para processar uma única imagem, a métrica mais crítica para avaliar a viabilidade de uma aplicação em tempo real.

E. Ambiente Computacional

Os experimentos foram executados em um ambiente Python (v3.10), com o *framework* de *deep learning* PyTorch (v2.1) e suporte de GPU NVIDIA (RTX 2080 8GB).

O *pipeline* de dados e a análise estatística foram suportados por um conjunto robusto de bibliotecas:

- Pré-processamento e Augmentation: *OpenCV* (v4.8) para manipulação de imagens, *MTCNN* [16] para detecção e alinhamento facial, e *Albumentations* (v1.3) para a aplicação das transformações.
- Análise e Métricas: *Scikit-learn* (v1.3) para o cálculo das métricas de classificação (como *F1-Score* e Matriz de Confusão), *NumPy* para operações numéricas e *Pandas* para a estruturação dos resultados.
- Utilitários e Visualização: *Matplotlib* para a geração de gráficos e *Tqdm* para o monitoramento de progresso durante o processamento.

O monitoramento de tempo e uso de memória (CPU/GPU) foi realizado para garantir a reprodutibilidade dos resultados de custo computacional.

IV. RESULTADOS E DISCUSSÃO

Nesta seção, apresentamos os resultados quantitativos e qualitativos dos quatro experimentos definidos na Seção III. A comparação entre o Experimento 1 (Baseline) e o Experimento 2 (Proposta) serve como um Estudo de Ablação, demonstrando a contribuição isolada do nosso *pipeline* de pré-processamento (balanceamento *offline* e *augmentation online*) para a performance final. Além disso, a análise compara o desempenho das arquiteturas ResNet-50, EfficientNet e EfficientViT em termos de métricas de classificação, robustez ao CDD e custo computacional.

A. Análise de Desempenho e Estudo de Ablação do Pipeline de Dados

Para avaliar o impacto do nosso *pipeline* de dados (Fase 2: Balanceamento *Offline* e Fase 3: *Augmentation Online*), comparamos diretamente os resultados do Experimento 1

(Baseline) com o Experimento 2 (Proposta). A Tabela II detalha essa comparação.

A análise revela uma dicotomia clara. No *dataset* RAF-DB, que é relativamente limpo, nossa proposta de balanceamento e *augmentation* foi benéfica para as arquiteturas mais modernas. O EfficientViT obteve o ganho mais expressivo, com um aumento de +5.95 pontos percentuais no *F1-Score Macro*, seguido pelo EfficientNet (+3.68 p.p.). Isso sugere que, em dados de boa qualidade, forçar a generalização com *augmentation* permite que esses modelos aprendam características mais robustas. A ResNet-50, por outro lado, sofreu uma leve queda (-1.50 p.p.), indicando que este *pipeline* de *augmentation* pode ser agressivo demais para arquiteturas clássicas.

Em contrapartida, no *dataset* ExpW, a proposta falhou em todas as arquiteturas. O EfficientNet teve a menor queda (-0.56 p.p.), mas todos os modelos performaram pior do que no *baseline*. A investigação da causa-raiz aponta para a qualidade dos dados do ExpW, que é um *dataset* notoriamente "sujo" (*dirty dataset*). Como observado em nossa análise exploratória e exemplificado na Figura 3, o ExpW contém uma quantidade significativa de amostras problemáticas: imagens com múltiplas faces (tornando o rótulo da emoção ambíguo), oclusões severas, e até mesmo imagens que não contêm nenhum rosto detectável.

O resultado do Experimento 2 no ExpW demonstra um princípio fundamental da Inteligência Artificial (ia): *garbage in, garbage out*. Ao aplicar *oversampling* (Fase 2) em um *dataset* com dados ruidosos, nosso *pipeline* inadvertidamente amplificou o ruído. O modelo foi treinado com mais intensidade em amostras de baixa qualidade, aprendendo a replicar os vieses e erros do *dataset* em vez de características faciais generalizáveis.




Figura 3. Exemplos de dados "sujos" do *dataset* ExpW. (a) Múltiplas faces com expressões distintas; (b) Oclusão severa; (c) Ausência de face clara. Imagens como estas degradam o desempenho do modelo quando ampliadas pelo *oversampling*.

B. Análise de Eficiência e Custo Computacional

O *trade-off* entre acurácia e eficiência, um dos focos deste trabalho, é detalhado na Tabela III. O EfficientNet-B0 se destacou como a arquitetura mais rápida para *treinamento*, completando o Experimento 2 no ExpW em apenas 3.75 horas. Isso é 1.6x mais rápido que a ResNet-50-50 (6.08h) e 5.8x mais rápido que o EfficientViT-B0 (21.70h).

Tabela II

RESULTADOS COMPARATIVOS DO EXPERIMENTO 1 (BASELINE) VS. EXPERIMENTO 2 (PROPOSTA). A MÉTRICA PRINCIPAL É O *F1-SCORE MACRO* (F1-M). TODOS OS VALORES EM PORCENTAGEM (%).

Modelo	RAF-DB (Teste)			ExpW (Teste)		
	Acc. (%)	F1-M (%)	Δ F1-M	Acc. (%)	F1-M (%)	Δ F1-M
<i>Experimento 1: Baseline (Dados Desbalanceados)</i>						
ResNet-50	78.32	68.86	–	60.16	43.25	–
EfficientNet-B0	75.75	66.61	–	61.35	41.93	–
EfficientViT-B0	69.69	59.77	–	56.45	39.17	–
<i>Experimento 2: Proposta (Dados Balanceados + Augmentation)</i>						
ResNet-50	76.53	67.36	-1.50	55.74	41.10	-2.15
EfficientNet-B0	79.34	70.29	+3.68	55.86	41.37	-0.56
EfficientViT-B0	75.00	65.72	+5.95	53.89	38.23	-0.94

Contudo, no quesito *inferência* — a métrica mais crítica para aplicações em tempo real — o EfficientViT-B0 (8.27ms/imagem) e a ResNet-50-50 (8.40ms/imagem) foram os mais rápidos, superando o EfficientNet-B0 (10.36ms/imagem).

Este resultado expõe um *trade-off* clássico de arquiteturas híbridas (CNN+ViT): o EfficientViT é computacionalmente muito custoso para treinar, mas altamente otimizado para inferência. O EfficientNet-B0, por sua vez, representa o melhor balanço para prototipagem e desenvolvimento rápido. O uso de VRAM foi similar e baixo em todas as arquiteturas (aprox. 1.5GB), não sendo um fator decisivo neste experimento.

Tabela III

CUSTO COMPUTACIONAL COMPARATIVO DAS ARQUITETURAS, MEDIDO DURANTE O EXPERIMENTO 2 (PROPOSTA) NO DATASET EXPW. O TEMPO DE INFERÊNCIA É A MÉDIA PARA PROCESSAR UMA ÚNICA IMAGEM 224x224.

Arquitetura	Tempo de Treino (Horas)	Pico VRAM (GB)	Inferência (ms / imagem)
ResNet-50	6.08	1.35	8.40
EfficientNet-B0	3.75	1.50	10.36
EfficientViT-B0	21.70	1.51	8.27

C. Análise de Robustez ao Cross-Dataset Drift (CDD)

A Tabela IV quantifica o desafio do CDD. Como esperado (Exp. 3), o desempenho dos modelos cai drasticamente ao serem testados em um *dataset* que não viram no treino. O EfficientNet-B0 treinado no RAF-DB alcança 70.29% de F1-Macro em seu próprio domínio, mas despenca para 19.76% ao ser testado no ExpW. Similarmente, o EfficientViT-B0 treinado no ExpW (38.23%) cai para 22.45% no RAF-DB. Isso confirma que os modelos aprendem vieses específicos de cada *dataset*, falhando em generalizar.

O Experimento 4 (Treino Combinado) se mostrou a estratégia de mitigação mais eficaz. Ao treinar os modelos em um "super *dataset*" (RAF-DB + ExpW), criamos modelos generalistas. O EfficientNet-B0, por exemplo, treinado de forma combinada, atingiu 70.14% no teste do RAF-DB e 41.87% no teste do ExpW. Notavelmente, esses valores são ligeiramente *superiores* (ou, no pior caso, equivalentes) aos modelos treinados em cada *dataset* individualmente.

Isso demonstra que, mesmo contendo ruído, a diversidade introduzida pelo ExpW ajudou a regularizar o modelo treinado no RAF-DB, e vice-versa. O treino combinado é, portanto, a

Tabela IV

ANÁLISE DE ROBUSTEZ AO CDD (EXPERIMENTOS 3 E 4). AS CÉLULAS COMPARAM O $F1\text{-SCORE}_{\text{MACRO}}$ (%) DOS MODELOS TREINADOS EM UM *DATASET* E TESTADOS EM OUTRO. A DIAGONAL (CINZA) REPRESENTA O TESTE NO PRÓPRIO DOMÍNIO (EXP. 2).

Arquitetura	Conjunto de Treino (Fonte)	Conjunto de Teste (Alvo): RAF-DB	Conjunto de Teste (Alvo): ExpW
ResNet-50	Treino RAF-DB (Exp. 2)	67.36	12.76
	Treino ExpW (Exp. 2)	15.11	41.10
	Treino Combinado (Exp. 4)	69.58	41.32
EfficientNet-B0	Treino RAF-DB (Exp. 2)	70.29	19.76
	Treino ExpW (Exp. 2)	12.82	41.37
	Treino Combinado (Exp. 4)	70.14	41.87
EfficientViT-B0	Treino RAF-DB (Exp. 2)	65.72	19.51
	Treino ExpW (Exp. 2)	22.45	38.23
	Treino Combinado (Exp. 4)	61.45	38.82

abordagem mais robusta para construir um sistema de FER *in-the-wild*, com o EfficientNet-B0 apresentando o melhor desempenho geral nesse cenário.

D. Análise Qualitativa e Estudo de Erros

Para complementar a análise quantitativa, a Figura 4 apresenta as matrizes de confusão normalizadas para a arquitetura EfficientNet-B0 (a de melhor desempenho combinado) no *dataset* RAF-DB, comparando o Baseline (Exp. 1) e a Proposta (Exp. 2).

A matriz (a) do Baseline evidencia um viés clássico de dados desbalanceados: o modelo tem dificuldade em classes minoritárias (como "Nojo", "Medo") e tende a confundi-las com classes majoritárias (como "Felicidade" ou "Neutro").

A matriz (b) da Proposta mostra os benefícios do nosso *pipeline* em dados limpos. A diagonal principal está visivelmente mais forte, indicando maior acurácia em todas as classes. Mais importante, as confusões entre classes minoritárias e majoritárias foram reduzidas. Por exemplo, a capacidade de distinguir "Nojo" e "Medo" aumentou, validando o impacto positivo do *oversampling* e *augmentation* para forçar o modelo a aprender características distintivas.




Figura 4. Matrizes de confusão para o modelo EfficientNet-B0 no *dataset* RAF-DB. (a) Modelo Baseline (Exp. 1), mostrando confusão nas classes minoritárias. (b) Modelo da Proposta (Exp. 2), mostrando melhor distinção entre classes após o balanceamento.

V. CONCLUSÕES

Este artigo realizou uma análise comparativa sistemática de três arquiteturas de DL — ResNet-50-50, EfficientNet-B0 e

EfficientViT-B0 — para a tarefa de FER *in-the-wild*, com foco na robustez ao CDD.

A principal descoberta do trabalho é a sensibilidade extrema dos modelos à qualidade dos dados de treinamento. Nosso *pipeline* de balanceamento e *augmentation* (Proposta) melhorou significativamente o desempenho no *dataset* limpo RAF-DB (especialmente para o EfficientViT, +5.95 p.p. F1-Macro), mas degradou o desempenho no *dataset* ruidoso ExpW. Isso demonstra que técnicas de *oversampling* podem ser prejudiciais se aplicadas sem um passo prévio de *data cleaning*, pois acabam por amplificar o ruído.

Confirmamos que o CDD é um obstáculo severo, com quedas de desempenho que ultrapassam 50 pontos percentuais em testes *cross-dataset*. A estratégia de mitigação mais bem-sucedida foi o Experimento 4 (Treino Combinado), que produziu modelos generalistas capazes de performar bem em ambos os domínios, com o EfficientNet-B0 apresentando o melhor balanço. Em termos de custo-benefício, o EfficientNet-B0 foi o mais rápido para treinar, enquanto o EfficientViT-B0, apesar do alto custo de treino, provou ser o mais rápido para inferência, tornando-o ideal para aplicações em tempo real.

Como trabalhos futuros, a principal direção é a implementação de um *pipeline* de ia centrada em dados (*Data-Centric AI*). Em vez de aplicar o *oversampling* cegamente, propomos o uso de técnicas de *data cleaning* automatizadas para identificar e remover amostras ruidosas (ex: imagens sem rosto, múltiplas faces) do *dataset* ExpW antes do balanceamento. Além disso, a exploração de técnicas de *data augmentation* mais avançadas, como a geração de amostras sintéticas via GANs ou modelos de difusão para as classes minoritárias, poderia gerar dados mais realistas e melhorar ainda mais a generalização dos modelos.

REFERÊNCIAS

- [1] F. Z. Canal, T. R. Müller, J. C. Matias, G. G. Scotton, A. R. S. Junior, E. Pozzebon, and A. C. Sobieranski, "A survey on facial emotion recognition techniques: A state-of-the-art literature review," *Information Sciences*, vol. 582, pp. 593–617, 2022.
- [2] S. Li, W. Deng, and J. Du, "Reliable crowdsourcing and deep locality-preserving learning for expression recognition in the wild," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 2852–2861.

- [3] M. Karnati, A. Seal, D. Bhattacharjee, A. Yazidi, and O. Krejcar, "Understanding deep learning techniques for recognition of human emotions using facial expressions: A comprehensive survey," *IEEE Transactions on Instrumentation and Measurement*, vol. 72, pp. 1–31, 2023.
- [4] B. Sahiner, W. Chen, R. K. Samala, and N. Petrick, "Data drift in medical machine learning: implications and potential remedies," *British Journal of Radiology*, vol. 96, no. 1150, p. 20220878, 2023.
- [5] R. Srinivasan and A. M. Martinez, "Cross-cultural and cultural-specific production and perception of facial expressions of emotion in the wild," *arXiv preprint arXiv:1808.04399*, 2018.
- [6] P. Lucey, J. F. Cohn, T. Kanade, Z. A. J. Saragih, and I. Mathews, "The extended cohn-kanade dataset (ck+): A complete dataset for action unit and emotion-specified expression," *Conf. IEEE Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2010.
- [7] M. J. Lyons, S. Akamatsu, J. G. M. Kamachi, and J. Budynek, "The japanese female facial expression (jaffe) database," *Proc. Third Int. Conf. Automatic Face and Gesture Recognition*, p. 14–16, 1998.
- [8] Z. Zhang, P. Luo, C. C. Loy, and X. Tang, "Expression in-the-wild (expw) dataset," <https://www.kaggle.com/datasets/shahzadabbas/expression-in-the-wild-expw-dataset>, 2015.
- [9] C. Dalvi, M. Rathod, S. Patil, S. Gite, and K. Kotecha, "A survey of ai-based facial emotion recognition: Features, ml & dl techniques, age-wise datasets and future directions," *IEEE Access*, vol. 9, pp. 164 066–164 089, 2021.
- [10] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [11] B. K. Durga and V. R. et al, "A resnet deep learning based facial recognition design for future multimedia applications," *Computers and Electrical Engineering*, no. 108384, p. 805–812, 2022.
- [12] M. Tan and Q. V. Le, "Efficientnet: Rethinking model scaling for convolutional neural networks," in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 2019, pp. 6105–6114.
- [13] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An image is worth 16x16 words: Transformers for image recognition at scale," in *International Conference on Learning Representations (ICLR)*, 2021.
- [14] H. Cai, C. Xiao, J. Li, and S. Han, "Efficientvit: Multi-scale linear attention for high-resolution dense prediction," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 12 384–12 394.
- [15] T. Shahzad, K. Iqbal, M. A. Khan, Imran, and N. Iqba, "Towards robust monocular depth estimation: Mixing datasets for zero-shot cross-dataset transfer," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 3, pp. 1623–1635, 2022.
- [16] K. Zhang, Z. Zhang, Z. Li, and Y. Qiao, "Joint face detection and alignment using multitask cascaded convolutional networks," in *IEEE Signal Processing Letters*, vol. 23, no. 10, 2016, pp. 1499–1503.
- [17] A. Buslaev, V. I. Iglovikov, E. Khvedchenya, A. Parinov, M. Druzhinin, and A. A. Kalinin, "Albumentations: Fast and flexible image augmentations," *Information*, vol. 11, no. 2, p. 125, 2020.